

Piano operativo — Arricchimento database: palestre e corsi

Progetto: Leisure Map · **Area pilota:** provincia di Treviso (poi estensione Veneto) · **Data:** luglio 2026

1. Obiettivo e perimetro

Aggiungere al catalogo due nuove famiglie di contenuti, integrate nella pipeline di ingestione trimestrale già progettata (adapter per piattaforme + estrazione HTML via LLM + vocabolario controllato):

- **Strutture:** palestre, centri fitness, sale arrampicata, piscine con attività, studi yoga/pilates, centri di arti marziali, centri danza.
- **Corsi:** l'offerta erogata dalle strutture (o da ASD indipendenti) — corso di yoga, corso base di arrampicata, acquagym, ecc.

Distinzione fondamentale del modello: **la struttura è il luogo, il corso è l'offerta**. Una palestra ha N corsi; un corso appartiene a una struttura (o a un luogo generico, es. un corso comunale in palestra scolastica). Sulla mappa si visualizzano le strutture; i corsi sono figli filtrabili.

Target quantitativo fase pilota: **~150 strutture e ~400 corsi** nella provincia di Treviso con completezza $\geq 80\%$ sui campi obbligatori.

2. Modello dati

2.1 Entità `struttura`

Campo	Tipo	Obbligatorio	Note
id	string	✓	slug stabile: pal- montebelluna- nomepalestra
nome	string	✓	
categoria	enum	✓	palestra arrampicata piscina yoga-pilates arti-marziali danza polivalente
lat, lng	float	✓	WGS84, precisione ≥ 5 decimali

Campo	Tipo	Obbligatorio	Note
indirizzo	string	✓	normalizzato (via, civico, CAP, comune)
comune	string	✓	chiave per le pagine località programmatiche
sito_web	url	○	fonte primaria per l'estrazione corsi
telefono	string	○	
orari	struttura OSM-like	○	formato <code>opening_hours</code> per il filtro "Aperto ora"
fascia_prezzo	enum	○	<code>€</code> <code>€€</code> <code>€€€</code> (abbonamento mensile: <40 / 40-70 / >70)
servizi	array enum	○	<code>sala-pesi</code> , <code>corsi-gruppo</code> , <code>piscina</code> , <code>sauna</code> , <code>parcheggio</code> , <code>accessibile</code>

Campo	Tipo	Obbligatorio	Note
prova_gratuita	bool	○	forte leva UX: filtro dedicato
fonte	array	✓	fonti che hanno contribuito al record
verificato_il	date	✓	alimenta il badge "Verificato: mese anno"
stato	enum	✓	attivo da- verificare chiuso

2.2 Entità `corso`

Campo	Tipo	Obbligatorio	Note
id	string	✓	
struttura_id	string	✓	FK; per corsi senza struttura fissa: luogo dedicato
nome	string	✓	es. "Yoga Vinyasa — livello base"
disciplina	enum	✓	vocabolario controllato, vedi

Campo	Tipo	Obbligatorio	Note
			2.3
livello	enum	✓	riusa il vocabolario esistente (per-tutti , principiante , intermedio , avanzato)
giorni_orari	array	○	[{giorno: "MA", inizio: "19:00", fine: "20:00"}]
prezzo	struct	○	{importo, periodo: mensile
iscrizioni_aperte	bool + date	○	fondamentale per corsi stagionali (settegiu)
eta_target	enum	○	bambini ragazzi adulti senior tutti
verificato_il / stato / fonte		✓	come sopra

2.3 Vocabolario controllato `disciplina`

Prima stesura (estendibile, mai valori liberi): `fitness-sala-pesi`, `crossfit-funzionale`, `yoga`, `pilates`, `arrampicata`, `nuoto`, `acquagym`, `arti-marziali`, `danza`, `zumba-fitness-musicale`, `ginnastica-dolce-posturale`, `padel-tennis`, `spinning`, `altro`.

Regola: l'estrattore LLM **deve** mappare su questo enum; se non ci riesce assegna `altro` + campo `disciplina_raw` per revisione periodica del vocabolario. Stesso principio già usato per i livelli di esperienza.

3. Fonti dati (strategia a cascata)

Ogni fonte ha un ruolo preciso; i campi si compongono per priorità, mai sovrascrittura cieca.

Fase A — Discovery delle strutture (chi esiste e dove)

1. **OpenStreetMap via Overpass API** — gratuita, licenza ODbL (richiede attribuzione, già prevista nella mappa). Query di partenza sul bounding box provinciale:

```
[out:json][timeout:60];
area["name"="Provincia di Treviso"]->.a;
( nwr["leisure"="fitness_centre"](area.a);
  nwr["leisure"="sports_centre"](area.a);

  nwr["sport"~"climbing|swimming|yoga|martial_arts|dance"](area.a);
```

```
);  
out center tags;
```

Fornisce: nome, coordinate, spesso sito web e orari.

Copertura stimata 50-70%.

2. **Google Places API (Text Search)** — per colmare i buchi: query tipo "palestra {comune}" per i ~95 comuni della provincia. Costo: free tier mensile poi a consumo; con ~300-500 richieste per ciclo trimestrale si resta in poche decine di euro al massimo.

⚠ **Vincolo ToS Google:** i dati Places non possono essere conservati stabilmente nel proprio DB (salvo `place_id` e coordinate). Usarla quindi come **fonte di discovery e verifica esistenza**, non come fonte dei contenuti pubblicati: nome/dettagli vanno poi presi dal sito ufficiale della struttura.

3. **Registro ASD/SSD (CONI/Sport e Salute) e affiliazioni CSEN/UISP/CSI** — elenchi pubblici delle associazioni sportive per comune: ottimi per intercettare i corsi non commerciali (arti marziali, danza, ginnastica) che non compaiono su Google.
4. **Fonti locali:** pagine sport dei siti comunali, Pro Loco, gruppi consiliari di quartiere — spesso pubblicano i corsi comunali di settembre. Ingestion semestrale mirata (settembre e gennaio) più che trimestrale, per seguire l'anno sportivo.

Fase B — Enrichment dei dettagli (cosa offrono)

5. Sito web della struttura → pipeline LLM già progettata:

fetch delle pagine `/corsi`, `/orari`, `/prezzi`
(individuate via sitemap o link interni), estrazione
strutturata con prompt che restituisce JSON conforme
allo schema §2, mapping sul vocabolario controllato. È
la fonte primaria per i corsi.

6. Pagine social (Facebook/Instagram) come fallback

solo quando il sito manca: molte ASD pubblicano orari
solo lì. Estrazione limitata a dati pubblici e non
personali; se il dato è irrecuperabile, il record resta `da-`
`verificare` con soli dati anagrafici.

7. Piattaforme di prenotazione fitness (es.

Wellhub/aggregatori corsi, sistemi di booking come
Sportclubby molto diffuso in Veneto): dove la struttura
espone un profilo pubblico, l'adapter dedicato — sul
modello degli adapter booking già progettati —
recupera palinsesto corsi e orari, che sono lì
tipicamente più aggiornati del sito.

Priorità di composizione per campo

`sito ufficiale` > `piattaforma booking` > `OSM` >
`registri ASD` > `social`, con eccezioni: coordinate da
OSM/geocoding (più precise), orari da piattaforma booking
se presente.

4. Pipeline operativa

Riusa l'architettura di ingestion trimestrale esistente, con
questi stadi:


```
[1 Discovery]      Overpass + Places Text
Search + registri ASD
    |              output: candidati grezzi
(nome, coordinate, eventuale sito)
[2 Dedup]          fuzzy match nome (Jaro-
Winkler  $\geq 0.88$ ) AND distanza < 150 m
    |              → merge in record unico con
lista fonti
[3 Geocoding]      per record senza coordinate:
Nominatim (rate limit 1 req/s,
    |              user-agent identificativo)
con verifica che il punto cada nel comune
atteso
[4 Fetch siti]     crawl leggero e rispettoso:
robots.txt, max 5 pagine/sito,
    |              1 req/s, cache HTML locale
per non ri-fetchare nel ciclo
[5 Estrazione LLM] HTML → JSON schema $2;
validazione con JSON Schema;
    |              confidence per campo; enum
obbligatori, `altro` + raw se dubbio
[6 Normalizzazione] orari in formato
opening_hours, prezzi in fasce,
    |              comune canonico, slug id
stabile
[7 QA]             regole automatiche
(coordinate nel bbox, prezzo plausibile,
    |              orari coerenti) + campione
manuale 10% per ciclo
[8 Pubblicazione] scrittura DB → build GeoJSON
statico (strutture) +
    |              JSON corsi → deploy su CDN
Vercel → pagine SSG rigenerate
```

Diff tra cicli: a ogni ingestion si confronta col ciclo precedente. Struttura scomparsa dalle fonti per 2 cicli consecutivi → `da-verificare` ; verifica manuale o telefonica fallita → `chiuso` (non si cancella: si mostra "non più attiva" per chi arriva da link vecchi, poi si rimuove dopo 2 cicli).

5. Qualità, fiducia, aspetti legali

- **Badge onestà:** ogni scheda espone `verificato_il` e la natura della fonte ("dati dal sito ufficiale", "segnalata dalla community"). Coerente col principio del progetto: mai comunicare più certezza di quanta il dato ne giustifichi.
- **Correzioni dal basso:** link "Segnala un'informazione errata" su ogni scheda (form → coda di revisione). È il canale di verifica più economico che esista.
- **Licenze:** dati OSM sotto ODbL → attribuzione "© Contributori OpenStreetMap" (già presente); dati Google Places non ripubblicati (solo discovery); contenuti dei siti riscritti/normalizzati, mai copiati testualmente nelle descrizioni.
- **Scraping:** rispetto di robots.txt e ToS; niente aree autenticate; rate limiting; user-agent con contatto. Per le piattaforme booking preferire API/feed ufficiali dove esistono.
- **GDPR:** non memorizzare dati personali (nomi istruttori, cellulari personali). Solo contatti "di struttura".

5.1 Raccolta manuale da Google Maps — cosa si può e cosa no

Google Maps è utilizzabile come **strumento di ricerca personale** per la discovery manuale, con questa distinzione:

Consentito (fatti nudi, non proprietà di Google):

- nome della struttura, indirizzo, coordinate, telefono, sito web
- trascritti manualmente, scheda per scheda, e poi **riverificati su fonte propria** (sito ufficiale o telefonata)

Vietato (contenuti della piattaforma):

- recensioni degli utenti e loro testi
- rating e numero di stelle "secondo Google"
- foto caricate su Maps, descrizioni generate da Google
- estrazione massiva/sistematica del database, anche manuale

Flusso operativo corretto:

1. Ricerca su Google Maps → individuo la struttura
2. Apro il sito ufficiale (o chiamo) → verifico i dati
3. Registro nel DB con `fonte: sito-ufficiale` (mai `fonte: google`) e `verificato_il: <data>`

Così il badge "Verificato" riflette anche la provenienza legittima del dato. Rating e recensioni, quando arriveranno, nasceranno dalla community di Leisure Map, non da fonti terze.

Descrizioni: generate dai fatti, mai da testi altrui.

Le descrizioni delle schede non si scrivono partendo dai testi di Google (né dal riassunto editoriale di Google né dalla descrizione del titolare) o di altre fonti: copiarne la formulazione, anche parafrasando frase per frase, tocca il diritto d'autore di chi le ha scritte. I fatti invece non sono protetti. Procedura:

1. Dalla fonte si estraggono solo **fatti in campi strutturati** (servizi, discipline, anno di apertura, peculiarità) — coerente con lo schema §2.
2. La descrizione viene **generata dai campi strutturati** con template editoriale proprio (a mano o via LLM della pipeline): es. "A {comune}, {nome} offre {servizi} con {peculiarità}...".
3. Test di controllo: descrizione propria e testo fonte fianco a fianco — se la struttura delle frasi si sovrappone, si riscrive; se condividono solo i fatti, è conforme.
4. Le schede esistenti scritte "per ispirazione" da testi terzi vanno rigenerate con questo metodo (retrofit una tantum, fattibile in blocco via LLM).

Beneficio collaterale: voce editoriale uniforme su tutto il catalogo, impossibile da ottenere copiando da fonti eterogenee.

Nota: inquadratura pratica, non parere legale. Alla scala del progetto (~150 strutture compilate una a una con verifica su fonte propria) è la prassi standard delle directory locali.

6. Fasi e tempi (stima realistica, lavoro serale/weekend)

Fase	Attività	Tempo
0	Schema DB + migrazione, vocabolario discipline v1	2-3 sere
1	Discovery: script Overpass + Places API, oppure ricerca manuale su Google Maps secondo il flusso §5.1; dedup, geocoding → prima lista strutture TV	1 settimana
2	Prompt di estrazione LLM per pagine corsi + validazione JSON Schema; test su 15 siti campione, misurando precisione per campo	1 settimana
3	Run completo provincia TV, QA campionaria, pubblicazione su mappa con nuove categorie fitness e corsi (già previste nel componente)	1 settimana
4	Adapter Sportclubby/booking + registri ASD; secondo run	1-2 settimane
5	Estensione ad altre province venete, una per ciclo trimestrale	continuo

KPI di ciclo: n. strutture attive · completezza campi obbligatori $\geq 80\%$ · % record **da-verificare** $< 15\%$ ·

precisione estrazione LLM su campione $\geq 90\%$ · età media del dato ≤ 100 giorni.

7. Decisioni aperte (da chiudere prima della fase 1)

1. **Piscine comunali e impianti pubblici:** dentro il perimetro pilota o fase 2? (fonti diverse: siti dei gestori, es. reti di gestione impianti).
2. **Prezzi:** mostrare importi puntuali (invecchiano male) o solo fasce €/€/€/€€€ con link alla fonte?
Raccomandazione: fasce sul catalogo, importo puntuale solo se da piattaforma booking aggiornata.
3. **Modello LLM per l'estrazione:** coerente con la strategia di costi già definita (GLM plan / free tier stack), con eventuale fallback su modello superiore solo per i siti che falliscono la validazione.